

졸음 감지 인공지능 개발 프로젝트

-서 동 관-

I. 배경

1.1. 교통사고의 심각성과 졸음운전의 위험성

교통사고는 현대 사회에서 가장 큰 문제 중 하나이다. 특히 졸음운전은 교통사고의 주요 원인 중 하나로 높은 위험성을 내포하고 있다. 운전 중 잠시 졸음이 찾아온다면 그 결과는 치명적일 수 있다. 예를 들어, 시속 100km로 달리던 운전자가 단 3초 동안 졸면, 그것은 84m를 맹목적으로 질주하는 것과 같다. 이런 졸음운전의 위험성은 통계를 통해 더욱 명확하게 확인할 수 있다. 2019년 기준 국내 교통사고 사망자의 약 24.8%가 졸음운전에 의해 발생한 것으로 확인되었는데, 이는 매우 경각심이 필요한 상황이다. 이에 본 프로젝트를 통해 이 문제를 해결해 보고자 하였다.




그림 1 졸음운전 고속도로 사망자 비율

1.2. 졸음운전에 대한 머신러닝 데이터 분석

다양한 프로젝트와 통계 분석을 통해 심각한 교통사고의 대부분은 운전자의 피로로 인해 발생한다

는 것이 밝혀졌다. 졸음운전의 위험성이 증가하고, 피로의 시작이 운전자에게 무감각하게 다가온다는 사실은 이를 중요한 공공 안전 문제로 만든다.

따라서 본 프로젝트에서는 인터넷을 통해 사전정보와 데이터를 얻고 이를 토대로 데이터에 대한 이해와 EDA 그리고 특성공학에 대해 자세히 살펴본 후 인사이트를 통해 중요 특성들을 도출하여 모델의 성능을 향상 시키고자 하였다.

도출된 중요 특성으로는 눈깜박임에 있어 두눈의 크기 차이와 두눈의 기울기 차이(전방주시) 그리고 눈을 감고 있는 시간의 차이로 구성하여 모델의 성능을 측정하였으며, 모델의 평가는 본 연구자가 직접 찍은 운전 영상을 활용하여 비교 평가하였다.

결과적으로 두눈의 크기 차이와 눈을 감고 있는 시간의 차이 그리고 두눈의 기울기 차이값이 크게 차이가 나는 것을 확인할 수 있었다.

그러나 표본의 과소로 이를 통계적으로 유의한지를 검증할 수 없었으며, 더불어 데이터의 과소로 일반화하기에는 문제가 있어 보이므로 향후 과제로 정해 대규모 데이터로 학습을 진행하여야 할 것으로 판단된다.

II. 프로젝트 목적

2.1. 졸음운전 예방의 필요성

이러한 위험성을 고려할 때, 졸음운전을 예방하기 위한 인공지능 모델 프로젝트는 더 이상 미룰 수 없는 필수적인 과제로 부상하였다. 이 프로젝트의 목적은 운전자의 졸음 상태를 실시간으로 감지하고 이를 즉각적으로 알려주는 인공지능 모델을 개발하는 것이다.

2.2. 실시간 졸음 상태 감지 및 알림 인공지능 모델의 개발 목표

이 모델이 최적화되면 향후 운전자들이 졸음운전의 위험성을 사전에 인지하고 대응할 수 있도록 도움을 줄 것이다. 실시간 졸음 상태 감지 및 알림 인공지능 모델의 개발을 통해 운전자의 졸음 상태를 신속하게 감지하고 사전 경고할 수 있는 기능을 제공해 줄 수 있기 때문이다. 이를 통해 교통사고의 발생을 줄일 수 있을 것이며, 더불어 사람들의 생명을 보호하는 데 큰 도움이 될 것이다.

III. 필요성

3.1. 졸음운전 예방 인공지능 모델의 중요성

졸음운전 예방을 위한 인공지능 모델은 운전자의 졸음 상태를 실시간으로 감지하고 경고하는 기능을 제공함으로써 이러한 위험 상황을 예방할 수 있다. 이를 통해 교통사고의 발생을 줄일 수 있으며, 이는 사람들의 생명을 보호하는 데 큰 도움이 되므로 사회적 파급효과는 크다고 말할 수 있다.

3.2. 사회적 손실 및 안전한 운전 문화 형성

또한, 이러한 인공지능 모델은 운전자에게 적절한 휴식 시간을 안내하거나, 졸음을 방지할 수 있는 다양한 콘텐츠를 제공하여 졸음을 효과적으로 방지하는 다양한 방법을 제공할 수 있을 것이다. 이를 통해 운전의 효율성을 높이고 운전자의 안전을 보장하면서 사회적, 경제적 손실을 크게 줄일 수 있다.

IV. 방법론

4.1. 컴퓨터 비전과 딥러닝의 활용

본 프로젝트에서는 운전자의 눈동자 움직임을 감지하는 컴퓨터 비전 기반의 인공지능 모델을 개발하는 것이다. 이를 위해 딥러닝 기술 중 하나인 Convolutional Neural Network (CNN)를 사용하여 운전자의 눈동자 상태를 분석하고 졸음 상태를 판단한다.

4.2. 데이터 증강 기법을 이용한 학습 성능 향상

또한, 기존의 데이터는 2586장의 train data와 288장의 valid data로 구성되어 있어서 딥러닝 학습에 있어 데이터의 과소로 과대적합과 일반화가 힘든 상황이다. 이를 해결하기 위해 본 프로젝트에서는 ImageDataGenerator를 활용하여 데이터를 3배 정도 증강시킴으로써 모델의 학습 성능을 향상시켰다. 이를 통해 모델의 일반화 성능을 개선하고 좀더 정확한 졸음 상태 감지가 가능해졌다.

V. 실험 설계

5.1. 운전자 눈동자 이미지 데이터 활용

본 프로젝트에서는 소규모의 운전자 눈동자 이미지 데이터를 활용하여 인공지능 모델을 학습시켰다. 이를 통해 모델이 부분적으로 추출된 운전자의 졸음 상태를 학습하고 정확하게 감지할 수 있도록 하였다.

5.2. 데이터 이해

본 데이터는 2586개의 train 데이터와 288개의 valid 데이터로 구성되어 있다. shape은 (2586,26,34,1),(288,26,34,1)이다.

데이터를 시각화하면 얼굴에서 눈만 추출되었으며 shape은 (26,34,1)로 구성되어있는 것을 확인할 수 있다.

데이터에서 확인할 수 있듯이 눈을 뜬 흑백 영상과 눈을 감은 흑백 영상으로 구성되어 있는 것을 확인할 수 있다.

따라서 예측시에는 open-cv의 cvtColor()함수를 활용하여 흑백 이미지로 처리하여야 할 것으로 보여진다.




그림 2 눈을 감은 상태 0, 눈을 뜬 상태 1

5.3. EDA(탐색적 데이터 분석)

본 데이터는 4차원의 이미지 데이터로 구성되어 있으며 .npy 형식으로 넘파이구조로 직렬화 되어 있으며, 흑백의 강도로 0~255의 값으로 저장되어 있다. 그리고 결측값은 없으며 데이터 라벨링은 눈을 감고 있으면 0, 눈을 뜨고 있으면 1로 되어 있음을 알 수 있다.

시각화로 matplotlib을 활용하여 시각화하여 눈 모양과 라벨값을 확인할 수 있다.

5.4. 특성공학

데이터의 특성을 도출하기 위해 아이가 조는 모습을 유심히 관찰하였다. 이를 통해 3가지 특성을 도출하였다.

첫째 졸음이 올 경우 두 눈의 크기의 변화에 차이가 있는 것을 확인할 수 있었다.

둘째 잠이든 경우는 1.5 초 이상을 눈을 감고 있었다.

셋째 졸음이 올 경우 두눈의 기울기에 차이가 있음을 알 수 있었다.

훈련 데이터는 일반적으로 정면에서 보이는 눈을 추출하였기에 본 프로젝트에서는 눈의 기울기와 감고 있는 시간 그리고 눈 깜박임 등의 측정에 사용하기에는 무리가 있을것으로 판단되어 데이터 증강을 활용하여 `rotation_range`, `width_shift_range`, `height_shift_range`, `shear_range`, `zoom_range` 로 증강할 필요가 있다

5.5. 가설 설정

EDA(탐색적 데이터 분석)와 특성공학을 토대로 하여 다음과 같이 귀무가설과 연구가설을 설정하였다.

귀무가설:

첫째 졸음이 올 경우 두 눈의 크기의 변화에 두 집단간 차이가 없다.

둘째 잠이든 경우를 판단할 시 두 집단간 시간의 차이가 없다.

셋째 졸음이 올 경우 두눈의 기울기에 두 집단간 차이가 없다.

연구가설:

첫째 졸음이 올 경우 두 눈의 크기의 변화에 두 집단간 차이가 있다.

둘째 잠이든 경우를 판단할 시 두 집단간 시간의 차이가 있다.

셋째 졸음이 올 경우 두눈의 기울기에 두 집단간 차이가 있다.



그림 4 두눈이 기울기 차이 50% 7프레임 이상



그림 3 두눈을 연속적으로 감고있는 시간 1.5초



그림 5 두눈의 차이 0.6이상 7프레임 이상

이를 통하여 본 프로젝트에서 실험을 통해 가설을 검증하고자 한다.

그러나 표본의 수가 제한적이어서 t-test를 통한 가설검정에는 한계가 있다.

이는 향후 과제로 삼을 필요가 있다.

이를 측정하는 알고리즘으로는 첫째 가설에 있어서 두눈을 학습한 인공지능 예측값의 차이가 0.6 이상이면 임계치로 설정한 7프레임이 지속되면 두눈의 크기 변화가 있는 것으로 설정하였다.

둘째 가설에 있어서 잠이든 경우를 판단하는 기준으로 1.5(45프레임)초간 지속적으로 예측값이 눈을 감고 있는 것으로 측정되면 잠이든 것으로 판단한다.

셋째 가설에 있어 기울기의 차이는 두눈의 X축 차이가 50%이상이면 기울기 차이가 있는 것으로 판단한다.

5.6. 데이터 증강을 이용한 학습 데이터 다양성 확보 및 모델 일반화 성능 향상

여러번의 학습을 통해 최적의 데이터 증강 파라미터를 도출하였다. ImageDataGenerator의 파라미터로 (rotation_range=40, width_shift_range=0.3, height_shift_range=0.5, shear_range=0.4, zoom_range=[0.8, 1.2]) 로 데이터 증강을 통해 학습 데이터의 다양성을 높임으로써 모델의 학습 성능을 개선하였다. 이를 통해 모델이 다양한 상황에서 좋은 상태를 좀더 정확하게 판단할 수 있도록 할 것으로 예상하였다.

```
•train_datagen= ImageDataGenerator(  
    rescale=1./255,  
    rotation_range=30,  
    width_shift_range=0.3,  
    height_shift_range=0.3,  
    shear_range=0.4, zoom_range= [0.8, 1.2])
```

5.7. 모델 구성

본 모델은 이진분류 문제를 해결하기 위한 모델로 이미지의 특성은 흑백의 눈 사진으로 구성되어 있어 비교적 간단한 모델로도 충분하다.

눈을 추출하는 데는 기존의 파이썬 라이브러리에서 제공하는 dlib를 활용하면 쉽게 얼굴의 특성들을 추출할 수 있고 이를 통해 눈의 특성값들을 추출하여 예측하는 데는 비교적 간단히 해결될 것으로 판단하였다.

따라서 모델은 기존의 서적을 통해 제공되어진 모델을 활용하여 Con2D층 3개와 MaxPool층 3개 그리고 마지막층에는 Dense층으로 구성하였다.

Cnn2D층의 하이퍼 파라미터로 filter는 (32, 64, 128)로 점점 늘어나게 구성하였으며, kernel_size는 3, stride는 1, padding=same activation은 relu를 활용하였다.

MaxPooling 연산은 풀링영역을 스트라이드 1로 이동하며 특성맵의 각 위치에서 최대값을 선택하여 특성 맵을 생성하게 된다. 이 과정은 특성 맵의 공간적인 차원을 축소하고, 중요한 특징을 강조하는 효과를 가지며, 동시에 계산량을 줄여 모델의 효율성을 높여주는 효과가 있다.

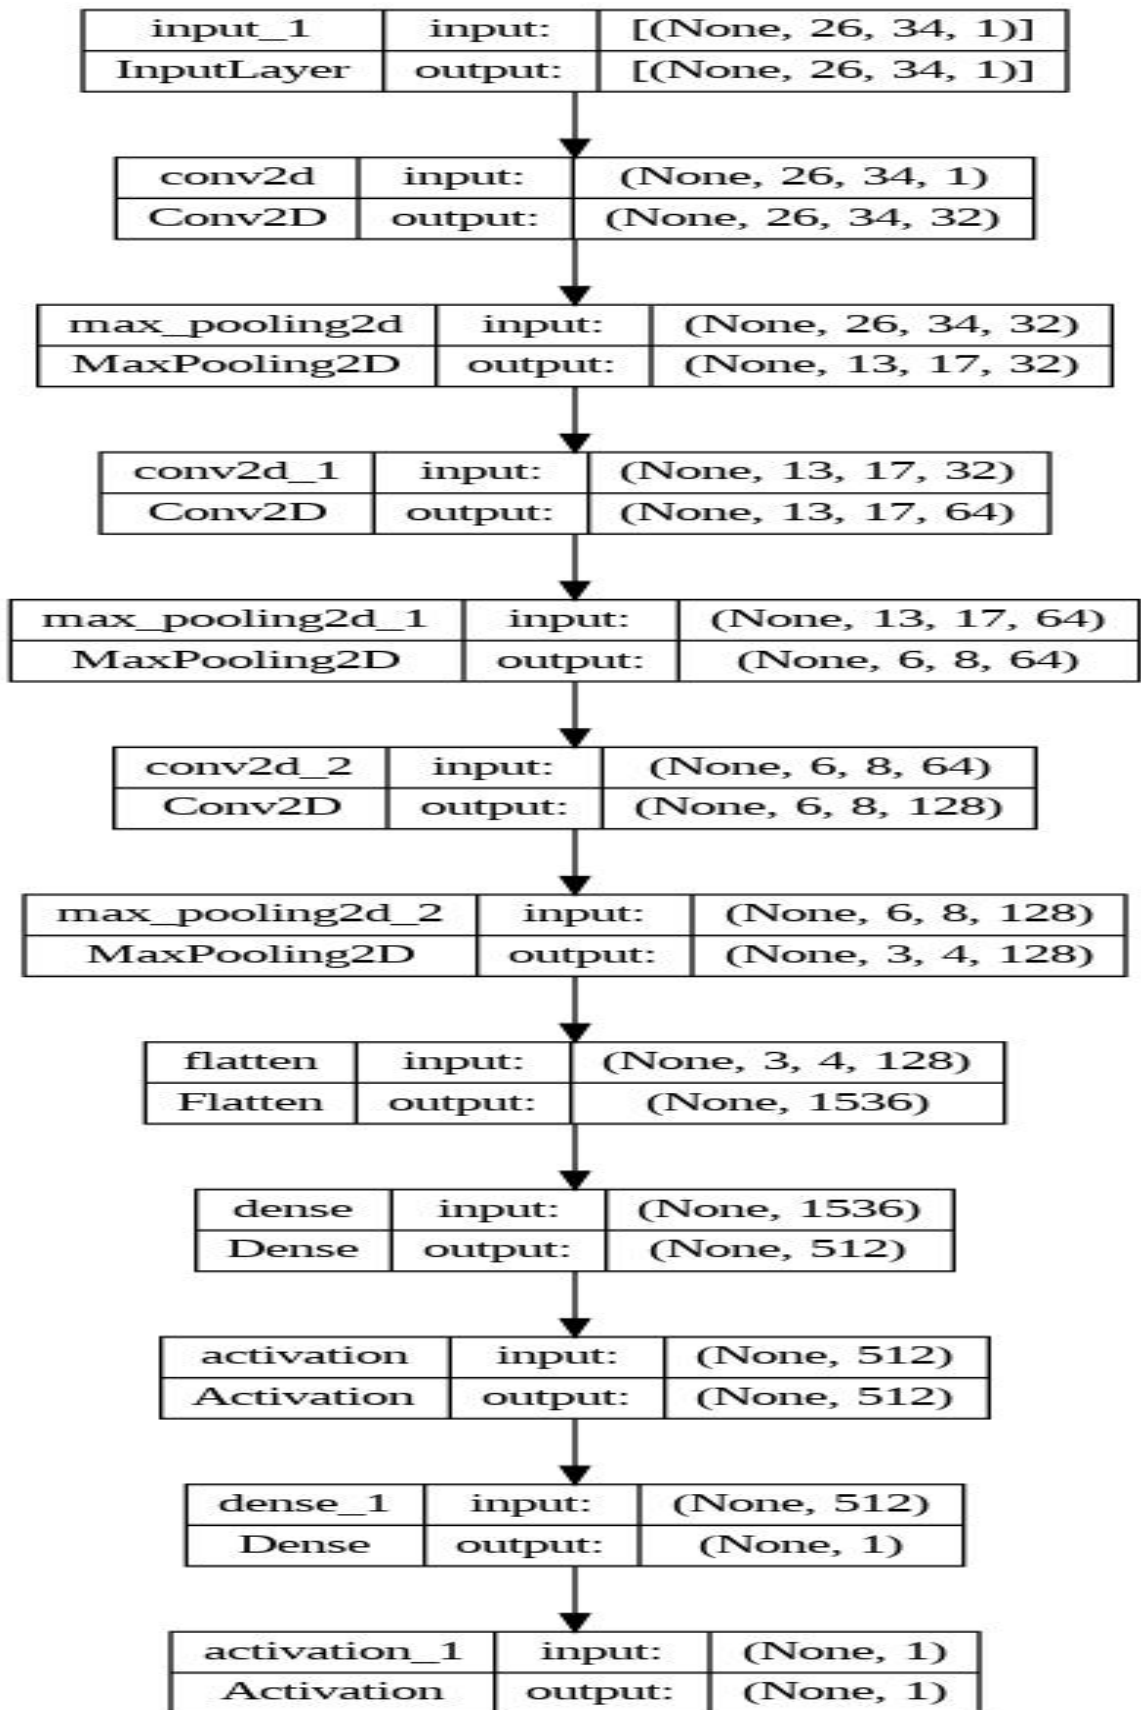


그림 6 모델 다이어그램

따라서 본 데이터에 있어서 MaxPooling2D의 pool_size는 2로 하였으며 MaxPooling2D연산이 눈의 특이점을 추출하는데 중요한 역할을 한다고 할 수 있다.

5.8. 하이퍼파라미터 설정

model.compile()은 optimizer는 adam을 loss는 binary_crossentropy metrics 는 acc를 사용하였으며, model.compile에서 optimizer는 adam을 loss는 binary_crossentropy를 metrics는 acc를 활용하였다.

model.fit_generator()에서는 epochs는 50를 하였으며 최적모델을 학습시 저장하기 위해 callbacks 함수를 통해 modelCheckpoint와 ReduceLROnPlate 사용하였으며 학습률은 1e-05로 최소값을 정해 학습을 수행하였다.

```
•model.fit(train_generator, epochs=50, validation_data=val_generator,
           callbacks=[
               ModelCheckpoint('models/%s.h5'%(start_time),monitor='val_acc',
               save_best_only=True, mode='max', verbose=1),
               ReduceLROnPlateau(monitor='val_acc',factor=0.2,  patience=10,  verbose=1,
               mode='auto', min_lr=1e-05)
```

5.9. 성능 평가와 ROC-AUC 및 confusion_matrix

성능 평가는 ROC AUC를 통해 수행하였습니다. 이를 통해 모델이 운전자의 졸음 상태를 얼마나 정확하게 감지할 수 있는지 평가하였다.

ROC-AUC는 머신러닝 모델의 성능을 평가하는 방법 중 하나로, 이진 분류 문제에서 자주 사용된다. ROC는 "Receiver Operating Characteristic"의 약자이고, AUC는 "Area Under the Curve"를 의미한다.

ROC 커브는 모델의 성능을 그래프로 표현한 것이며, y축에는 진짜 양성 비율 (TPR: True Positive Rate)을, x축에는 거짓 양성 비율 (FPR: False Positive Rate)을 놓는다. 이 두 가지 비율을 사용하여 모델이 다양한 분류 임계값에서 어떻게 작동하는지를 보여준다.

TPR (True Positive Rate)은 실제 양성 케이스 중에서 얼마나 많은 양성 케이스를 양성으로 정확히 예측했는지를 나타낸다.

FPR (False Positive Rate)은 실제 음성 케이스 중에서 얼마나 많은 음성 케이스를 양성으로 잘못 예측했는지를 나타낸다.

모델의 성능이 더 좋을수록 ROC 커브는 왼쪽 상단 모서리에 가까워지며, AUC (Area Under the Curve) 값이 1에 가까워진다. 반대로, 모델의 성능이 좋지 않을수록 ROC 커브는 대각선에 가까워지며, AUC 값이 0.5에 가까워진다. AUC는 ROC 커브 아래의 영역을 측정하므로, 이 값이 클수록 분류 모델의 성능이 좋다고 평가할 수 있다.

본 프로젝트에서는 소량의 데이터를 활용하므로 과대적합 문제가 발생할 여지가 크기에 데이터 증

```

Epoch 46: ReduceLROnPlateau reducing learning rate to 4.000001893898055e-05.
81/81 [=====] - 1s 12ms/step - loss: 0.0461 - acc: 0.9853 - val_loss: 0.0288 - val_acc: 0.9931 - lr: 2.0000e-04
Epoch 47/50
81/81 [=====] - ETA: 0s - loss: 0.0372 - acc: 0.9899
Epoch 47: val_acc did not improve from 0.99306
81/81 [=====] - 1s 13ms/step - loss: 0.0372 - acc: 0.9899 - val_loss: 0.0274 - val_acc: 0.9896 - lr: 4.0000e-05
Epoch 48/50
80/81 [=====>.] - ETA: 0s - loss: 0.0396 - acc: 0.9863
Epoch 48: val_acc did not improve from 0.99306
81/81 [=====] - 1s 14ms/step - loss: 0.0392 - acc: 0.9865 - val_loss: 0.0283 - val_acc: 0.9931 - lr: 4.0000e-05
Epoch 49/50
78/81 [=====>..] - ETA: 0s - loss: 0.0403 - acc: 0.9851
Epoch 49: val_acc did not improve from 0.99306
81/81 [=====] - 1s 14ms/step - loss: 0.0406 - acc: 0.9845 - val_loss: 0.0309 - val_acc: 0.9931 - lr: 4.0000e-05
Epoch 50/50
79/81 [=====>..] - ETA: 0s - loss: 0.0447 - acc: 0.9841
Epoch 50: val_acc did not improve from 0.99306
81/81 [=====] - 1s 12ms/step - loss: 0.0441 - acc: 0.9845 - val_loss: 0.0293 - val_acc: 0.9931 - lr: 4.0000e-05
<keras.callbacks.History at 0x7f7ec05ee140>

```

그림 7 학습 진행률

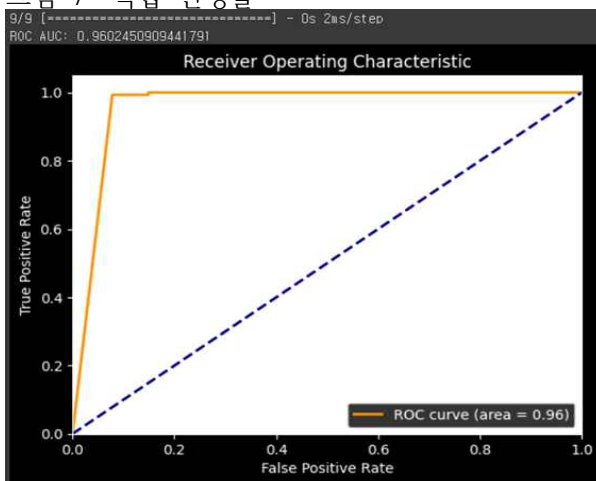


그림 8 ROC-AUC 곡선




그림 9 혼동행렬

강을 하여 적용하였으나 ROC-AUC 가 거의 100%에 가깝게 나왔다.

이를 해결하는 방법으로 드롭아웃이나, R2규제, R1규제를 활용할 수 있으나 데이터의 특성이 눈

을 감았는지 눈을 떴는지를 확인하는 간단한 모델이기에 과적합은 일반적이다 할 수 있다.

혼동행렬(confusion_matrix)는 다양한 성능지표를 계산할 수 있다. 예를 들어 정확도, 정밀도, 재현율, F1 점수 등을 계산할 수 있다. 이러한 성능지표는 혼동 행렬의 값을 기반으로 계산된다.

본 프로젝트에서 학습과 추론의 결과는 데이터의 과소와 데이터의 추출 특성의 단조로움으로 val_acc가 0.9931, val_loss가 0.0293 으로 거의 100% 예측을 성공하였다.

또한 confusion_matrix를 통해 결과값을 예측해보니 test acc가 0.993055555로 나타나 거의 100% 예측에 성공하였다.

허나 이는 데이터의 양 부족으로 인한 과대적합으로 볼 수 있고 향후 빅데이터를 확보하여 추가 분석하며 드롭아웃이나 정규화 과정을 적용하여 규제를 가해 일반화 성능을 높여야 할것이라 판단 된다.



그림 10 frame_warning_threshold:7fps diff_threshold: 0.6




그림 11 frame_warning_threshold:7fps diff_threshold: 0.6

이 임계치를 미세 조정하여 좀더 정확한 예측을 수행할 수 있을것으로판단됨

이와 함께 졸음이 오는 아이 영상과 본인이 직접 운전하며 찍은 영상을 test해 본 결과 졸음

이 오는 아이 영상의 경우 졸음경고 횟수 34회, 눈 깜빡임 경고 횟수 3회 전방주시 경고횟수 158 회로 나타났으며 본인의 운전 영상의 경우 졸음경고 횟수 0회, 눈 깜빡임 경고 횟수 0회, 전방주시 경고 횟수 3회로 나타나서 본 프로젝트 모델의 성능이 괜찮은걸 알 수 있었다.

허나 이 두 영상 표본을 가지고 앞서 설정한 연구가설 설정이 통계적으로 유의한지를 검증할 수는 없을 것으로 판단된다.

통계적 검증을 위해서는 최소한 150개 이상의 표본의 데이터가 추가 확보되어야 하며 이를 통해 집단간 평균의 차이를 검증하여 가설을 검증하여야 할 것으로 판단된다. 이는 향후 프로젝트 과제로서 한계라고 할 수 있다.

VI. 파급효과

프로젝트에서 개발된 졸음운전 예방을 위한 인공지능 모델의 가설이 통계적으로 유의하게 나온다면 큰 파급효과를 가져올 것으로 예상된다. 이 모델의 도입과 활용은 실제로 교통사고를 줄이고 도로의 안전성을 높일 것이다.

또한, 이 모델은 운전의 효율성을 높이고 운전자의 안전을 보장하면서 사회적, 경제적 손실을 줄이는 데 큰 도움이 될 것입니다.

VII. 결론

본 프로젝트에서는 운전자의 졸음 상태를 실시간으로 감지하고 이를 즉각적으로 알려주는 인공지능 모델을 개발하였다. 이를 위해 컴퓨터 비전과 딥러닝 기술을 활용하였으며, 소규모의 운전자 눈동자 이미지 데이터를 활용하여 인공지능 모델을 학습시켰다. 이를 통해 모델이 부분적으로 추출된 운전자의 졸음 상태를 학습하고 정확하게 감지할 수 있도록 하였으며, 데이터 증강 기법을 활용하여 모델의 학습 성능을 향상시켰다. 또한, 모델의 성능 평가를 위해 ROC-AUC와 confusion_matrix를 사용하였으며, val_acc가 0.9931, val_loss가 0.0293 으로 거의 100% 예측을 성공하였다.

실제적용을 위해 졸음이 오는 아이 영상과 본인이 직접 운전하며 찍은 영상을 test해 본 결과 졸음이 오는 아이 영상의 경우 졸음경고 횟수 34회, 눈 깜빡임 경고 횟수 3회 전방주시 경고횟수

158회로 나타났으며 본인의 운전 영상의 경우 졸음경고 횟수 0회, 눈 깜빡임 경고 횟수 0회, 전방주시 경고 횟수 3회로 나타나서 본 프로젝트 모델의 성능이 괜찮은걸 알 수 있었다.

그러나 이는 데이터의 양 부족으로 인한 과대적합으로 볼 수 있고 향후 빅데이터를 확보하여 추가 분석하며 드롭아웃이나 정규화 과정을 적용하여 규제를 가해 일반화 성능을 높여야 할것이다.

본 프로젝트에서 개발된 졸음운전 예방을 위한 인공지능 모델의 가설이 통계적으로 유의하게 나온다면 큰 파급효과를 가져올 것으로 예상된다. 이 모델의 도입과 활용은 실제로 교통사고를 줄이고 도로의 안전성을 높일 것이다. 또한, 이 모델은 운전의 효율성을 높이고 운전자의 안전을 보장하면서 사회적, 경제적 손실을 줄이는 데 큰 도움이 될 것이다.

끝으로 프로젝트의 한계와 향후 과제로 표본의 수가 적어 실제 적용하여 통계적 가설 검증을 할 수 없었기에 일반화하기에 무리가 있고 이를 해결하기 위해 많은 실제 데이터를 활용하여 학습과 추론을 한 후 실제 데이터에 적용하여 검증한다면 일반화가 가능할 것으로 판단된다.